Dictionnaire des variables

Base base_clients_modelisation : une ligne par client, 2 592 clients, 32 colonnes

Ce que contient la base

Les données viennent du jeu Online Retail (UCI) : les ventes d'un e-commerçant britannique, du 1er décembre 2010 au 9 décembre 2011. Les montants sont en livres sterling. Chaque ligne de la base décrit un client, à une date de référence fixée au **9 novembre 2011**. Les variables sont toutes calculées avec les achats faits jusqu'à cette date. La variable à prédire (`churn`) regarde ce qui se passe après.

Seuls les clients actifs sont gardés : ceux qui ont acheté au moins une fois dans les 90 jours avant le 9 novembre 2011.

Nettoyage fait avant le calcul

Lignes de départ	541 909
Lignes sans numéro de client (retirées)	134 697
Annulations (factures commençant par C, retirées des achats et comptées à part)	9 288
Doublons exacts (retirés)	5 192
Quantité ou prix négatif ou nul (retirés)	40
Frais de port, ajustements et autres lignes qui ne sont pas des produits (retirés)	1 683
Lignes d'achat conservées	391 009

Identifiant

Variable	Description	Type / unité
`CustomerID`	Numéro du client, tel qu'il figure dans les données d'origine. Un numéro apparaît une seule fois.	Entier

Historique d'achat (jusqu'au 9 novembre 2011)

Variable	Description	Type / unité
nb_factures	Nombre de factures du client.	Entier
nb_jours_achat	Nombre de jours différents où le client a acheté. Deux factures le même jour comptent pour un jour.	Entier
nb_articles_total	Nombre total d'articles achetés (somme des quantités).	Entier
nb_produits_distincts	Nombre de produits différents achetés (codes produit distincts).	Entier
depense_totale	Somme dépensée par le client depuis son premier achat.	Livres
panier_moyen	Dépense totale divisée par le nombre de factures.	Livres
anciennete_jours	Nombre de jours entre le premier achat et le 9 novembre 2011.	Jours
frequence_achat_mensuelle	Nombre de factures divisé par l'ancienneté en mois de 30 jours. L'ancienneté est comptée pour au moins 1 mois, pour ne pas diviser par un nombre trop petit.	Factures par mois
intervalle_moyen_jours	Nombre moyen de jours entre deux jours d'achat. Vide si le client n'a acheté qu'un seul jour (681 clients).	Jours
nb_annulations	Nombre de lignes d'annulation du client avant le 9 novembre 2011.	Entier

Activité récente

Variable	Description	Type / unité
recence_jours	Nombre de jours entre le dernier achat et le 9 novembre 2011. Va de 0 à 90 puisque seuls les clients actifs sont gardés.	Jours
nb_factures_30j	Nombre de factures dans les 30 jours avant le 9 novembre 2011. Vaut 0 s'il n'y en a pas.	Entier
depense_30j	Somme dépensée dans les 30 jours avant le 9 novembre 2011.	Livres
nb_factures_90j	Nombre de factures dans les 90 jours avant le 9 novembre 2011.	Entier
depense_90j	Somme dépensée dans les 90 jours avant le 9 novembre 2011.	Livres

Date du dernier achat

Variable	Description	Type / unité
mois_dernier_achat	Mois du dernier achat (1 = janvier, 12 = décembre).	1 à 12
jour_semaine_dernier_achat	Jour de la semaine du dernier achat (1 = lundi, 7 = dimanche).	1 à 7

Pays

Variable	Description	Type / unité
pays	Pays du client à son achat le plus récent. Une grande majorité des clients sont au Royaume-Uni.	Texte

Catégories d'achat

Variable	Description	Type / unité
categorie_principale	Catégorie dans laquelle le client a le plus dépensé.	Texte
part_noel_et_saisonnier	Part de la dépense en articles de Noël et de saison (Noël, Pâques, Halloween).	0 à 1
part_bijoux_et_accessoires	Part de la dépense en bijoux, accessoires, sacs à main, écharpes.	0 à 1
part_bougies_lumieres_et_parfums	Part de la dépense en bougies, lumières, lanternes, encens et parfums.	0 à 1
part_jouets_jeux_et_enfants	Part de la dépense en jouets, jeux et articles pour enfants.	0 à 1
part_fete_et_anniversaire	Part de la dépense en articles de fête : anniversaire, ballons, guirlandes, pique-nique.	0 à 1
part_papeterie_cartes_et_emballage	Part de la dépense en papeterie, cartes, papier cadeau, rubans, étiquettes.	0 à 1
part_cuisine_et_art_de_la_table	Part de la dépense en cuisine et art de la table : tasses, assiettes, boîtes à gâteaux, ustensiles.	0 à 1
part_sacs_et_rangement	Part de la dépense en sacs, boîtes, paniers et rangement.	0 à 1
part_jardin_et_exterieur	Part de la dépense en articles de jardin et d'extérieur.	0 à 1
part_decoration_maison	Part de la dépense en décoration : cadres, miroirs, horloges, coussins, cœurs.	0 à 1
part_autre	Part de la dépense en produits qu'aucune règle n'a pu classer (environ 6 % des produits).	0 à 1

Pour chaque client, les 11 parts s'additionnent à 1. Les catégories ont été créées à partir des mots des descriptions des produits (en anglais), avec une liste de mots-clés. Un produit peut donc être mal classé, la liste de règles est au début du fichier preparation_donnees.py.

Variable à prédire

Variable	Description	Type / unité
churn	1 si le client n'achète rien dans les 30 jours qui suivent le 9 novembre 2011 (du 10 novembre au 9 décembre 2011), 0 s'il achète au moins une fois.	0 ou 1

Sur les 2 592 clients actifs : 1 490 avec churn = 1 et 1 102 avec churn = 0, soit 57,5 % de churn.

À retenir pour la modélisation

Le numéro de client (CustomerID) sert à identifier la ligne, il ne doit pas entrer dans le modèle. Toutes les autres variables ne regardent que le passé, avant le 9 novembre 2011 ; seule la variable churn regarde après. La base ne contient qu'une date de référence, donc le découpage entre apprentissage et test se fait au hasard, en gardant la même proportion de churn dans les deux parties.